Diffusion Model

Hung Manh

Ngày 14 tháng 10 năm 2026

Nội dung trình bày

1. Looped Model: Tóm tắt
2. Looped Model: Giới thiệu
3. LM: Kiến thức nền tảng
4. LM: Phương pháp luận
5. LM: Nghiên cứu liên quan
6. LM: Thử nghiệm và Đánh giá
7. LM: Kết luận
8. Embedded Language Flows (ELF)
9. FMLM: Tóm tắt
10. FMLM: Bối cảnh & Thách thức
11. FMLM: Mô hình cơ sở FLM
12. FMLM: Phương pháp luận Flow Map
13. FMLM: Dẫn hướng trong suy luận
14. FMLM: Thử nghiệm và Đánh giá
15. FMLM: Kết luận

Looped Model: Tóm tắt

- **Vấn đề:** Giải bài toán khó cần nhiều compute time. Các looped models thực hiện điều này qua việc cập nhật các hidden state. Tuy nhiên, huấn luyện qua nhiều vòng lặp có thể khiến gradient suy giảm khi truyền ngược khiến việc các early updates gặp khó khăn.
- **Đề xuất: Looped flows** - huấn luyện recurrency với các mục tiêu khử nhiễu cục bộ.
- **Cơ chế:**
  - *Temporal alignment*: Giảm dần mức độ nhiễu và sử dụng shared noise.
  - *Inference*: Tích phân vận tốc của probability flow kết hợp với các looped states.
- **Kết quả:** Vượt qua các SOTA looped models, đạt **58.8%** trên ARC-AGI-1 và **12.2%** trên ARC-AGI-2; cho phép scale tính toán và tạo multiple valid predictions.

1. Giới thiệu: Bối cảnh & Thách thức

Bối cảnh & Động lực:

- Giải bài toán khó đòi hỏi gia tăng tính toán lúc inference.
- Khác với Autoregressive LLMs, các looped models sử dụng distributed state và cập nhật tuần hoàn để tích lũy computation.

Thách thức của Looped Models:

- Huấn luyện bằng full BPTT tốn kém bộ nhớ và dễ gặp hiện tượng vanishing/exploding gradients.
- Thực tế chỉ backprop qua vài bước $\rightarrow$ early updates không nhận được tín hiệu để hỗ trợ future computation.
- Hậu quả: Chuỗi lặp không ổn định, sinh ra các failure modes ở cả bài toán đơn giản.

1. Giới thiệu: Giải pháp Looped Flows

Đóng góp chính của Looped Flows:

- Học một chuỗi mục tiêu khử nhiễu cục bộ theo thời gian ở nhiều mức nhiễu khác nhau.
- **Temporal alignment:** Phân bổ huấn luyện theo thời gian, giảm dần mức nhiễu, sử dụng shared noise $\rightarrow$ hidden states duy trì tính ổn định.
- **Cơ chế Inference:** Giải bài toán bằng cách tích phân trường vận tốc của probability flow kết hợp với recurrent states.
- **Lợi ích:**
  - Mở rộng tính toán: Chia quá trình suy luận thành nhiều bước thời gian nhỏ hơn để tăng độ chính xác.
  - Tạo nhiều dự đoán hợp lệ: Sử dụng phương pháp tích phân Euler hoặc tích phân ngẫu nhiên để tạo ra nhiều phương án dự đoán.
  - Học vòng lặp ổn định: Giúp mô hình học cách cập nhật trạng thái ổn định hơn, khắc phục những hạn chế của các mô hình lặp trước đây.

2. Kiến thức nền: Looped Models

- **Định nghĩa:** Cập nhật hidden state $z \in \mathbb{R}^{d_z}$ qua hàm f:

$$z_i = f(z_{i-1}; c)$$

- Đưa ra dự đoán qua đầu đọc g: $\hat{x}_i = g(z_i)$.
- **Hàm loss thực tế:** Để tránh full BPTT, mô hình dùng toán tử dừng gradient $sg(\cdot)$:

$$L_{loop}(f, g) := \mathbb{E}_{c,x}\left[\sum_i CE(\hat{x}_i, x)\right] \quad \text{với } z_i = f(sg(z_{i-1}); c)$$

- *Điểm yếu:* Loss tại bước $\geq i$ không truyền tín hiệu về quá khứ $z_{<i}$. Quá trình lặp deterministic chỉ cho phép 1 lời giải duy nhất.

2. Kiến thức nền: Flow and Diffusion Models

- **Continuous flow matching:** Đi từ nhiễu $x_0 \sim \mathcal{N}(0, \sigma^2 I)$ đến dữ liệu thật $x_1 \sim p_{data}$.
- **Probability path:** Nội suy $I_t := (1-t)x_0 + tx_1$.
- **Velocity field:** $\dot{x}_t = b_t(x_t; c)$.
- Tích phân số (VD: Euler tiến) để xấp xỉ lời giải:

$$x_{t_{i+1}} = x_{t_i} + (t_{i+1} - t_i)\hat{b}_{t_i}(x_{t_i}; c)$$

- **Denoising function (D_t):** Thay vì dự đoán trực tiếp vận tốc, học hàm khử nhiễu độc lập tại mỗi t:

$$L_{flow}(\hat{D}) := \mathbb{E}[CE(\hat{x}_t, x_1)]$$

- *Nhược điểm:* Mô hình phụ thuộc hoàn toàn vào quá trình flow để cập nhật trạng thái, nên khó học các phép tính cần thực hiện theo đúng thứ tự qua nhiều bước.

3. Looped Flows: Cơ chế Huấn luyện

Stateful Denoiser:

- Khử nhiễu x_{t_i} đồng thời cập nhật looped state z_{t_i}:

$$(\hat{x}_{t_i}, z_{t_i+1}) = \hat{D}_{t_i}(I_{t_i}, sg(z_{t_i}); c)$$

Temporal Alignment:

- Sắp xếp lưới thời gian $t_0 < t_1 < \cdots < t_k$ để mức nhiễu giảm dần.
- **Shared noise:** Mẫu x_0 dùng chung cho toàn bộ quỹ đạo $\rightarrow$ ép mô hình liên kết các thời điểm, giúp z_{t_i} mang thông tin hữu ích cho tương lai.

Adaptive Computation Time (ACT):

- Dùng đầu đọc phân loại nhị phân $q(z_{t_i+1})$ để quyết định dừng suy luận sớm khi độ chính xác đã bão hòa.

3. Looped Flows: Cơ chế Suy luận

- **Stochastic Integration:**
  - Thêm hệ số ngẫu nhiên $\gamma \geq 0$.
  - Lùi nhẹ x_{t_i} về thời điểm $s < t_i$ (tiêm nhiễu mới) trước khi thực hiện bước Euler tiến.
  - Khi $\gamma = 0$, mô hình quay về Euler ODE truyền thống.
- **Inference-time Scaling:**
  - Giải bài toán bằng finer time grid so với lúc huấn luyện.
  - Sử dụng kỹ thuật **best-Q ensembling**: Chạy nhiều mẫu, chọn dự đoán có xác suất thành công cao nhất từ đầu đọc ACT q.

4. Nghiên cứu liên quan

- **Looped models (TRM, FPRM):** Thiếu giám sát toàn cục do cắt gradient, dễ rơi vào spurious attractors. *Looped flows giải quyết bằng cách khởi tạo lặp từ local denoising.*
- **Stochastic looped models:** Tận dụng nhiễu nhưng vẫn phụ thuộc gradient cục bộ. *Looped flows kết hợp lợi ích ngẫu nhiên và giải quyết triệt để học cục bộ.*
- **Flow & Diffusion Models:** Học khử nhiễu độc lập. *Looped flows dùng local objectives tạo lộ trình học mượt mà cho hidden state.*
- **Energy models:** *Looped flows tương đương việc học chuỗi năng lượng làm mịn giảm dần*, giúp quá trình tối ưu dễ dàng hơn.

5. Thử nghiệm: Chính xác & Khả năng mở rộng

So sánh đơn quỹ đạo (Single-trajectory):

- Looped flows áp đảo TRM, FPRM, GRAM trên:
  - Sudoku-Extreme (**97.9%**)
  - Maze-Hard (**86.7%**)
  - ARC-AGI-1 (**58.8%** - tăng từ 44.6% của TRM)
  - ARC-AGI-2 (**12.2%** - tăng từ 7.8% của TRM)

Inference-time scaling:

- Ensembling cải thiện thêm hiệu năng (Sudoku 99.3%, ARC 59.5%).
- Finer time grid tăng accuracy mạnh: Sudoku từ 74.5% (8 steps) $\rightarrow$ 97.9% (128 steps).

Độ ổn định:

- Giải quyết 90.9% các trường hợp thất bại của TRM (bao gồm non-convergence và spurious attractors).

5. Thử nghiệm: Đa dạng Lời giải & Ablation Study

Đa dạng lời giải (Diversity): Đánh giá trên bài toán đa nghiệm.

- N-Queens (8x8): **99.9%** ACC / **91.4%** Coverage.
- Graph Coloring (8 đỉnh): **0.7** conflicts / **89.4%** Coverage.
- Vượt trội hoàn toàn về khả năng tìm ra tập lời giải đa dạng nhờ probability transport.

Ablation Study:

- **Flow:** Bỏ time conditioning, bỏ interpolant, không giảm nhiễu, hay không chia sẻ nhiễu đều làm giảm mạnh hiệu năng.
- **Recurrence:** So với mô hình không lặp (FLM) hoặc self-conditioning, Looped flows đạt khả năng tổng quát hóa tốt nhất trên test set.
- Tích phân SDE ($\gamma = 5$) cho kết quả tốt hơn Euler ODE ($\gamma = 0$).

6. Kết luận

- **Looped Flows** là một framework giải quyết vấn đề huấn luyện của Looped Models thông qua các mục tiêu khử nhiễu cục bộ.
- **Temporal alignment** giúp trạng thái lặp xây dựng computation hữu ích trên toàn cục, khắc phục hoàn toàn điểm yếu của gradient ngắn hạn.
- Mở ra khả năng **inference-time scaling** mạnh mẽ qua lưới thời gian mịn và tích phân ngẫu nhiên.
- **Hướng tương lai:** Phát triển các thuật toán huấn luyện không cần mô phỏng (simulation-free training).

ELF: Tổng quan bài báo

- **Ý tưởng cốt lõi:** Mô hình khuếch tán ngôn ngữ liên tục dựa trên Flow Matching trong latent space.
- **Đóng góp chính:**
  - Chứng minh continuous diffusion hoàn toàn vượt trội discrete diffusion trên ngôn ngữ nếu khử nhiễu hoàn toàn trong không gian nhúng liên tục.
  - Chỉ thực hiện rời rạc hóa (discretization/decoding) tại bước cuối cùng ($t = 1$).
  - Sử dụng mạng chia sẻ trọng số giữa denoising và decoding, tích hợp sẵn Classifier-Free Guidance (CFG) lúc huấn luyện.

1. ELF: Bối cảnh & Phân loại DLMs

Bối cảnh:

- Diffusion và flow-based models là tiêu chuẩn vàng trong sinh ảnh/video, đang được mở rộng sang xử lý ngôn ngữ.

Phân loại mô hình khuếch tán ngôn ngữ :

- *Discrete:* Thao tác trực tiếp trên token (trước đây được ưu tiên do dễ tối ưu hóa).
- *Continuous:* Ánh xạ token sang không gian biểu diễn liên tục để tiến hành khử nhiễu.

Giải pháp đề xuất của ELF:

- Khử nhiễu hoàn toàn trong không gian nhúng liên tục.
- Định nghĩa Continuous Velocity Field với Flow Matching.
- Dùng mạng chia sẻ trọng số, chỉ rời rạc hóa tại bước $t = 1$.

2. ELF: Framework

- **Từ rời rạc sang liên tục:** Chuỗi token $s \in \mathcal{V}^L$ được chuyển sang biểu diễn liên tục x bằng bộ mã hóa frozen T5.
- **Nội suy tuyến tính:** Tạo biến ẩn z_t dọc theo đường đi:

$$z_t = tx + (1-t)\epsilon, \quad t \in [0,1], \quad \epsilon \sim \mathcal{N}(0, \mathrm{I})$$

- **Flow Velocity:** Đạo hàm theo thời gian:

$$v = \frac{dz}{dt} = x - \epsilon$$

- **Dự đoán x:** Trực tiếp dự đoán biểu diễn sạch $x_\theta(z_t, t)$ thay vì dự đoán vận tốc v, giúp mạng nơ-ron hoạt động ổn định ở số chiều cực cao.

3. ELF: Hàm mục tiêu & Rời rạc hóa

- **Nhánh khử nhiễu (Denoising - chiếm 80% trọng số):** Tối thiểu hóa sai số MSE của trường vận tốc dự đoán:

$$\mathcal{L}_{\text{MSE}} = \mathbb{E}_{t,x,\epsilon}\left[\frac{1}{(1-t)^2}\|x_\theta(z_t, t) - x\|^2\right]$$

- **Nhánh giải mã (Decoding - chiếm 20% trọng số):**
  - Tại bước cuối $t = 1$, biến đổi z_t thành phân phối token qua ma trận unembedding W.
  - Dùng chung trọng số với mạng khử nhiễu, huấn luyện bằng Cross-Entropy:

$$\mathcal{L}_{\text{CE}} = \mathbb{E}_{\tilde{z}}\left[\text{CrossEntropy}(Wx_\theta(\tilde{z}), s)\right]$$

4. ELF: Conditioning & Guidance

- **Self-conditioning:** Thực hiện lượt truyền thứ hai điều kiện hóa trên dự đoán trung gian $\hat{x}'$ từ bước trước để tăng độ mượt của quỹ đạo.
- **Classifier-Free Guidance (CFG):** Dễ dàng áp dụng trong miền liên tục:

$$v_{\text{cfg}}(z_t \mid c) = \omega v(z_t \mid c) + (1 - \omega) v(z_t \mid \emptyset)$$

- **Training-time CFG:** Tích hợp thẳng CFG vào hàm mục tiêu vận tốc ngay từ lúc huấn luyện $\rightarrow$ loại bỏ hoàn toàn chi phí tính toán kép khi suy luận.
- **Sinh có điều kiện:** Ghép prompt vào trước chuỗi mục tiêu; phần prompt được giữ nguyên không làm nhiễu.

5. ELF: Kết quả thực nghiệm

Sinh không điều kiện (OpenWebText):

- Ở 32 bước lấy mẫu, ELF-B (105M) đạt **Gen. PPL 24.08**, vượt trội so với các đối thủ rời rạc như MDLM (104.29) và Duo (62.47).
- **Hiệu quả dữ liệu cực cao:** Đạt đỉnh chỉ với 45B token huấn luyện (ít hơn $\sim$10 lần so với $>$ 500B tokens của các baseline).

Progressive Distillation:

- Cho phép giảm số bước lấy mẫu xuống mức cực ít (**1 đến 4 bước**) mà vẫn duy trì chất lượng sinh văn bản xuất sắc.

Sinh có điều kiện:

- **Tóm tắt XSum:** ROUGE-1 đạt **36.0** (đánh bại các mô hình tự hồi quy cùng kích cỡ).
- **Dịch máy WMT14:** Đạt BLEU **26.4**.

6. ELF: Kết luận & Đóng góp

- **Khẳng định:** Mô hình khuếch tán ngôn ngữ liên tục hoàn toàn có thể cạnh tranh và vượt trội hơn các phương pháp rời rạc.
- **Bí quyết tối ưu của ELF:**
  1. Giữ toàn bộ quỹ đạo làm nhiễu trong không gian nhúng liên tục.
  2. Chỉ thực hiện rời rạc hóa ở bước thời gian cuối cùng ($t = 1$).
  3. Sử dụng mạng chia sẻ trọng số, loại bỏ bộ giải mã phụ trợ rườm rà.
- **Tác động:** Mở ra tiềm năng tạo văn bản chất lượng cao với chi phí huấn luyện thấp và tốc độ suy luận cực nhanh.

FMLM: Tóm tắt bài báo

- **Vấn đề:** Discrete diffusion models sinh song song thay thế autoregressive LLMs, nhưng chất lượng ko tốt ở few-step regime ($1 \sim 4$ bước) do lỗi factorization approximation.
- **Đề xuất: Flow Map Language Models (FMLM)** — mô hình hóa ngôn ngữ bằng continuous flows trên biểu diễn one-hot unconstrained.
- **Cơ chế:**
  - *Flow Language Model (FLM)*: Đưa bài toán về denoiser trên simplex, huấn luyện bằng cross-entropy và time reparameterization theo decoding error.
  - *Two-time denoiser ($\delta_{s,t}$)*: Tham số hóa flow map nằm trọn trên simplex, chưng cất bằng semigroup condition.
- **Kết quả:** FMLM đạt khả năng sinh văn bản one-step vượt qua chất lượng 8 bước của discrete diffusion baselines, tăng tốc **8.3**$\times$, hỗ trợ continuous guidance ổn định.

FMLM: Giới hạn của Discrete Diffusion

Hạn chế của Autoregressive LLMs:

- Sinh tuần tự từng token một ($O(L)$ bước tính toán), tạo ra điểm nghẽn lớn về tốc độ khi sinh chuỗi dài.

Factorization Error của Discrete Diffusion:

- Discrete diffusion (MDLM, Duo) khử nhiễu trên không gian chuỗi $\mathcal{V}^L$.
- Do không gian trạng thái quá lớn, mô hình bắt buộc phải dùng xấp xỉ phân rã tích:

$$\tilde{p}_{t|s}(\mathrm{y}_t|\mathrm{y}_s) := \prod_{l=1}^{L} p^l_{t|s}(y^l_t|\mathrm{y}_s)$$

- Giả định các token độc lập có điều kiện chỉ đúng trong giới hạn vô cùng bé ($t \to s$).
- *Hậu quả ở few-step ($1 \sim 4$ bước):* Bước nhảy lớn làm mất hoàn toàn tương quan ngữ nghĩa giữa các token $\to$ văn bản vô nghĩa (PPL > 1000) hoặc lặp từ liên tục (entropy collapse < 4.0).

FMLM: Paradigm Shift

Bác bỏ định kiến về Discrete Modalities:

- Quan niệm phổ biến cho rằng dữ liệu rời rạc bắt buộc phải dùng discrete noising process.
- **Giới hạn toán học:** Trong không gian rời rạc hữu hạn S, không tồn tại bất kỳ deterministic map $f : S \to S$ nào trên từng mẫu để biến đổi một phân phối tùy ý về phân phối đích.
- Hệ quả: discrete diffusion không thể có flow map tất định trên từng mẫu để đưa nhiễu về dữ liệu chỉ trong 1 bước.

Giải pháp Continuous Flows:

- Nhúng token dạng one-hot lossless vào không gian Euclid không ràng buộc $\mathbb{R}^{L\times|\mathcal{V}|}$.
- Dòng liên tục trong $\mathbb{R}^{L\times|\mathcal{V}|}$ sở hữu một flow map tất định duy nhất trên từng mẫu, mở đường cho việc sinh 1 bước chính xác.

FMLM: Mô hình cơ sở Flow LM (FLM)

- **Stochastic Interpolant:** Nội suy đường đi giữa Gaussian noise $x_0 \sim \mathcal{N}(0, I)$ và one-hot data x_1:

$$I_t := (1-t)x_0 + tx_1$$

- **Thách thức dự đoán velocity:** Học vận tốc $b_t = \mathbb{E}[x_1 - x_0 | I_t]$ bằng MSE bị rank bottleneck do x_0 full-rank $\rightarrow$ underfitting.
- **Chuyển sang Denoiser trên Simplex:**

$$D_t(x) := \mathbb{E}[x_1 | I_t = x], \quad b_t(x) = \frac{D_t(x) - x}{1-t}$$

  - $D_t(x)^l = p^l_{1|t}(\cdot | I_t = x) \in \Delta^{|\mathcal{V}|-1}$ (luôn nằm trên simplex xác suất).
  - Huấn luyện bằng **Cross-Entropy loss** thích ứng với hình học one-hot, chặn khoảng cách Wasserstein $W_2^2 \leq C\epsilon$.

FMLM: Time Reparameterization

- **Vấn đề:** Tỷ lệ lỗi giải mã $P_e(t) := \frac{1}{L}\sum_l \mathbb{P}(g^l(\mathrm{x}_t) \neq g^l(\mathrm{x}_1))$ dốc đứng sát $t = 1$.
  - Lấy mẫu đều $t \sim \mathcal{U}[0,1]$ lãng phí tín hiệu ở vùng chưa quyết định token và bỏ sót vùng quyết định then chốt khi $|\mathcal{V}|$ lớn.
- **Đề xuất hàm $\tau(t)$ chuẩn hóa tiến độ giải mã:**

$$\tau(t) = 1 - \frac{|\mathcal{V}|}{|\mathcal{V}| - 1} P_e(t)$$

- **Lợi ích:**
  - Huấn luyện và lấy mẫu đều trong không gian $\tau(t) \sim \mathcal{U}[0,1]$.
  - Mỗi bước tính toán đóng góp đồng đều vào việc giảm decoding error.
  - Giúp mô hình huấn luyện ổn định với từ vựng lớn $|\mathcal{V}| \approx 50.000$.

FMLM: Two-time Denoiser trên Simplex

Mục tiêu Flow Map:

- Ánh xạ trực tiếp giữa hai thời điểm bất kỳ: $X_{s,t}(\mathrm{x}) = \mathrm{x} + (t-s)\mathrm{v}_{s,t}(\mathrm{x})$.
- Cho phép sinh 1 bước qua $\hat{\mathrm{x}}_1 = X_{0,1}(\mathrm{x}_0)$.
- *Thách thức:* $X_{s,t}$ và $\mathrm{v}_{s,t}$ rời khỏi simplex do nhiễu Gaussian $\rightarrow$ dùng MSE cho chất lượng rất kém.

Định nghĩa Two-time Denoiser ($\delta_{s,t}$):

$$\delta_{s,t}(\mathrm{x}) := \mathrm{x} + (1-s)\mathrm{v}_{s,t}(\mathrm{x})$$

4 Tính chất cốt lõi:

1. Phục hồi chính xác Flow Map: $X_{s,t}(\mathrm{x}) = \frac{1-t}{1-s}\mathrm{x} + \frac{t-s}{1-s}\delta_{s,t}(\mathrm{x})$.
2. Bảo toàn trên simplex: $\delta_{s,t}(\mathrm{x})^l \in \Delta^{|\mathcal{V}|-1} \rightarrow$ dùng được softmax output.
3. Khớp với denoiser thông thường trên đường chéo: $\delta_{s,s}(\mathrm{x}) = D_s(\mathrm{x})$.
4. Thỏa mãn semigroup dạng tổ hợp lồi: $\delta_{s,t} = \gamma\delta_{s,u} + (1-\gamma)\delta_{u,t}(X_{s,u})$.

Hàm mất mát Semigroup Distillation:

- Tận dụng tính chất tổ hợp lồi trên simplex, tối ưu qua KL divergence:

$$\mathcal{L}_{\mathrm{KL}}(\hat{\delta}) = \mathbb{E}_{s,u,t}\left[\sum_{l=1}^{L} \mathrm{KL}(\bar{\delta}^{l}_{s,t} \parallel \hat{\delta}^{l}_{s,t}(I_s))\right] + \mathbb{E}_{t}\left[\sum_{l=1}^{L} \mathrm{KL}(\hat{D}_t(I_t)^{l} \parallel \hat{\delta}^{l}_{t,t}(I_t))\right]$$

với teacher: $\bar{\delta}_{s,t} := sg\left(\gamma\hat{\delta}_{s,u}(I_s) + (1-\gamma)\hat{\delta}_{u,t}(\hat{X}_{s,u})\right)$, và $\hat{D}_t$ là FLM teacher đã đóng băng.

Kỹ thuật then chốt:

- **Boundary sampling:** Do $\tau(t)$ phẳng gần $t = 0$, cố định xác suất $p = 1/32$ lấy mẫu cặp $(s, t) = (0, 1)$ để bơm gradient mạnh cho bước nhảy 1-step.
- **One-step inference:** $\hat{x}_1 = \hat{\delta}_{0,1}(x_0)$ sau đó decode qua argmax.

FMLM: Continuous Inference Guidance

Autoguidance (Nâng cao chất lượng sinh không điều kiện):

- Ngoại suy vận tốc ra xa model yếu: $\hat{\mathrm{b}}_t^{(\text{guided})} = \hat{\mathrm{b}}_t^{(\text{weak})} + \eta(\hat{\mathrm{b}}_t - \hat{\mathrm{b}}_t^{(\text{weak})})$.
- Nhờ hoạt động trong không gian Euclid, FLM duy trì tính ổn định ở η lên đến **100** (giảm PPL từ 96.9 xuống **51.6** tại $\eta = 50$).
- Discrete diffusion kq ko tốt ở $\eta \geq 10$ do ngoại suy logit nhân bản factorization error.

Reward Guidance (FMRG - Điều hướng theo thuộc tính):

- Flow map $X_{t_n,1}$ cung cấp khả năng **look-ahead vi phân** tới điểm cuối:

$$\mathrm{x}_{t_{n+1}} = X_{t_n,t_{n+1}}(\mathrm{x}_{t_n}) + \lambda \nabla r\left(X_{t_n,1}(\mathrm{x}_{t_n})\right)$$

- Classifier/Reward model r chỉ cần huấn luyện trên **văn bản sạch**, không cần train trên dữ liệu nhiễu như discrete diffusion.

FMLM: Hiệu năng sinh nhiều bước & Đột phá One-step

Chế độ nhiều bước (1024 steps):

- FLM vượt trội các baseline SOTA trên cả LM1B và OpenWebText (OWT):
  - LM1B ($L = 128$): FLM PPL **96.91** vs Duo 98.14, MDLM 109.21, CANDI 120.99.
  - OWT ($L = 1024$): FLM PPL **62.23** vs Duo 77.69, MDLM 105.15.

Chế độ cực ít bước (1, 2, 4 steps) — FMLM One-step Breakthrough:

- Discrete diffusion chưng cất (MDLM+SDTT, Duo+DCD, Di4C) sụp đổ ở 1 bước (PPL > 1000 hoặc entropy collapse < 4.0).
- **FMLM 1-step:** Đạt PPL **119.34** trên LM1B và **168.30** trên OWT.
  - Chất lượng 1 bước tương đương mô hình rời rạc chưng cất ở $8 \sim 16$ bước.
  - Tăng tốc độ sinh **8.3**$\times$.
  - Self-BLEU (0.073) và GPT-4.1 Judge xác nhận không bị mode collapse.

FMLM: Cấu trúc logic (Sudoku) & Ablation Study

Mô hình hóa ràng buộc logic toàn cục (Sudoku 9×9):

- *Unconditional 1-step:* FMLM đạt **9.38%** lời giải hợp lệ (discrete baselines đều $= 0.00\%$).
- *Conditional 1-step (20 clues):* FMLM giải đúng **39.84%** chỉ trong 1 forward pass.

Ablation Study (Bảng 18):

- **Loss & Parameterization:** Denoiser + Softmax + CE (**96.91**) $\gg$ Denoiser + MSE (129.04) $\gg$ Velocity + MSE (3801.36 - không hội tụ).
- **Time Schedule:** Decoding error schedule $\tau(t)$ (**106.98**) $\gg$ Uniform (149.18).
- **Distillation Objective:** Semigroup (**119.34**) $\gg$ Eulerian (149.13) $\gg$ Lagrangian (193.08) do không cần JVP tốn kém và bất ổn định.
- **Boundary sampling ($p = 1/32$):** Cải thiện PPL 1-step từ 142.61 xuống **119.34**.

FMLM: Kết luận & Định hướng

- **Continuous Flow vượt trội trên ngôn ngữ:** Bác bỏ giả thuyết bắt buộc phải dùng discrete diffusion cho dữ liệu rời rạc; continuous flow cho chất lượng cao hơn và suy luận nhanh hơn.
- **Two-time Denoiser trên Simplex:** Cầu nối lý thuyết giúp chưng cất flow map ổn định bằng cross-entropy / semigroup condition.
- **Khả năng mở rộng:** Hỗ trợ autoguidance ổn định và reward-guided generation hiệu quả với look-ahead vi phân.
- **Hạn chế & Hướng tương lai:**
  - Ma trận nhúng $O(L|\mathcal{V}|)$ tốn thêm khoảng 30% bộ nhớ lúc huấn luyện $\rightarrow$ hướng giải quyết bằng sparse gradients.
  - Tiềm năng ứng dụng lớn cho reinforcement learning finetuning (RLFT) nhờ giảm chi phí rollout tính reward.

Cảm ơn bạn đã theo dõi!

Q&A