# Embedded Language Flows (ELF)

## Mô hình Khuếch tán Ngôn ngữ Liên tục dựa trên Flow Matching

Hung Manh

October 21, 2026

# Nội dung trình bày

# ELF: Tổng quan bài báo

- **Tên bài báo:** *Embedded Language Flows (ELF)*
- **Ý tưởng cốt lõi:** Mô hình khuếch tán ngôn ngữ liên tục dựa trên Flow Matching trong không gian nhúng biểu diễn (latent space).
- **Đóng góp chính:**
  - Chứng minh continuous diffusion hoàn toàn vượt trội discrete diffusion trên ngôn ngữ nếu khử nhiễu hoàn toàn trong không gian nhúng liên tục.
  - Chỉ thực hiện rời rạc hóa (discretization/decoding) tại bước cuối cùng ($t = 1$).
  - Sử dụng mạng chia sẻ trọng số giữa denoising và decoding, tích hợp sẵn Classifier-Free Guidance (CFG) lúc huấn luyện.

# 1. ELF: Bối cảnh & Phân loại DLMs

**Bối cảnh:**

- Diffusion và flow-based models là tiêu chuẩn vàng trong sinh ảnh/video, đang được mở rộng sang xử lý ngôn ngữ.

**Phân loại mô hình khuếch tán ngôn ngữ (DLMs):**

- *Rời rạc (Discrete):* Thao tác trực tiếp trên token (trước đây được ưu tiên do dễ tối ưu hóa).
- *Liên tục (Continuous):* Ánh xạ token sang không gian biểu diễn liên tục để tiến hành khử nhiễu.

**Giải pháp đề xuất của ELF:**

- Khử nhiễu hoàn toàn trong không gian nhúng liên tục.
- Định nghĩa trường vận tốc qua thời gian liên tục với Flow Matching.
- Dùng mạng chia sẻ trọng số, chỉ rời rạc hóa tại bước $t = 1$.

# 2. ELF: Khung làm việc (Framework)

- **Từ rời rạc sang liên tục:** Chuỗi token $s \in \mathcal{V}^L$ được chuyển sang biểu diễn liên tục $x$ bằng bộ mã hóa T5 đông cứng.
- **Nội suy tuyến tính (Rectified Flows):** Tạo biến ẩn $z_t$ dọc theo đường đi:

$$z_t = tx + (1-t)\epsilon, \quad t \in [0,1], \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

- **Trường vận tốc dòng (Flow Velocity):** Đạo hàm theo thời gian:

$$v = \frac{dz}{dt} = x - \epsilon$$

- **Dự đoán $x$ (x-prediction):** Trực tiếp dự đoán biểu diễn sạch $x_\theta(z_t, t)$ thay vì dự đoán vận tốc $v$, giúp mạng nơ-ron hoạt động ổn định ở số chiều cực cao.

# 3. ELF: Hàm mục tiêu & Rời rạc hóa

- **Nhánh khử nhiễu (Denoising - chiếm 80% trọng số):** Tối thiểu hóa sai số MSE của trường vận tốc dự đoán:

$$\mathcal{L}_{\text{MSE}} = \mathbb{E}_{t,x,\epsilon}\left[\frac{1}{(1-t)^2}\|x_\theta(z_t,t) - x\|^2\right]$$

- **Nhánh giải mã (Decoding - chiếm 20% trọng số):**
  - Tại bước cuối $t = 1$, biến đổi $z_t$ thành phân phối token qua ma trận unembedding $W$.
  - Dùng chung trọng số với mạng khử nhiễu, huấn luyện bằng Cross-Entropy:

$$\mathcal{L}_{\text{CE}} = \mathbb{E}_{\tilde{z}}\left[\text{CrossEntropy}(Wx_\theta(\tilde{z}), s)\right]$$

# 4. ELF: Điều kiện hóa & Dẫn hướng (Guidance)

- **Self-conditioning:** Thực hiện lượt truyền thứ hai điều kiện hóa trên dự đoán trung gian $\hat{x}'$ từ bước trước để tăng độ mượt của quỹ đạo.
- **Classifier-Free Guidance (CFG):** Dễ dàng áp dụng trong miền liên tục:

$$v_{\text{cfg}}(z_t \mid c) = \omega v(z_t \mid c) + (1 - \omega) v(z_t \mid \emptyset)$$

- **Training-time CFG:** Tích hợp thẳng CFG vào hàm mục tiêu vận tốc ngay từ lúc huấn luyện $\rightarrow$ loại bỏ hoàn toàn chi phí tính toán kép khi suy luận.
- **Sinh có điều kiện:** Ghép prompt vào trước chuỗi mục tiêu; phần prompt được giữ nguyên không làm nhiễu.

# 5. ELF: Kết quả thực nghiệm

**Sinh không điều kiện (OpenWebText):**

- Ở 32 bước lấy mẫu, ELF-B (105M) đạt **Gen. PPL 24.08**, vượt trội so với các đối thủ rời rạc như MDLM (104.29) và Duo (62.47).
- **Hiệu quả dữ liệu cực cao:** Đạt đỉnh chỉ với 45B token huấn luyện (ít hơn $\sim$10 lần so với $> 500$B tokens của các baseline).

**Chưng cất lũy tiến (Progressive Distillation):**

- Cho phép giảm số bước lấy mẫu xuống mức cực ít (**1 đến 4 bước**) mà vẫn duy trì chất lượng sinh văn bản xuất sắc.

**Sinh có điều kiện:**

- **Tóm tắt XSum:** ROUGE-1 đạt **36.0** (đánh bại các mô hình tự hồi quy cùng kích cỡ).
- **Dịch máy WMT14:** Đạt BLEU **26.4**.

# 6. ELF: Kết luận & Đóng góp

- **Khẳng định:** Mô hình khuếch tán ngôn ngữ liên tục hoàn toàn có thể cạnh tranh và vượt trội hơn các phương pháp rời rạc.
- **Bí quyết tối ưu của ELF:**
  1. Giữ toàn bộ quỹ đạo làm nhiễu trong không gian nhúng liên tục.
  2. Chỉ thực hiện rời rạc hóa ở bước thời gian cuối cùng ($t = 1$).
  3. Sử dụng mạng chia sẻ trọng số, loại bỏ bộ giải mã phụ trợ rườm rà.
- **Tác động:** Mở ra tiềm năng tạo văn bản chất lượng cao với chi phí huấn luyện thấp và tốc độ suy luận cực nhanh.

# Cảm ơn bạn đã theo dõi!

Q&A