Flow Map Language Models (FMLM)

Mô hình hóa Ngôn ngữ Đơn bước qua Khử nhiễu Liên tục

Hung Manh

October 26, 2026

Nội dung trình bày

1 Mô hình ngôn ngữ ánh xạ dòng FMLM

FMLM: Tổng quan bài báo

- **Tên bài báo:** *Flow Map Language Models: One-step Language Modeling via Continuous Denoising*
- **Tác giả và tổ chức:** Chanhyuk Lee, Nicholas M. Boffi, Jinwoo Kim et al., KAIST và CMU, arXiv:2602.16813
- **Ý tưởng cốt lõi:** Chạy dòng liên tục trên biểu diễn one-hot của token, rồi chưng cất thành ánh xạ dòng để sinh văn bản chỉ với một bước.
- **Đóng góp nổi bật:**
  - **Phản bác định kiến:** Dòng liên tục cạnh tranh được với khuếch tán rời rạc ngay cả trên dữ liệu rời rạc.
  - **Bộ khử nhiễu hai thời điểm $\delta_{s,t}$:** Luôn nằm trên đơn hình xác suất, nên huấn luyện ánh xạ dòng bằng KL và cross-entropy thay vì sai số bình phương.
  - **Sinh một bước:** Gen. PPL 119,34 trên LM1B, trong khi các mô hình khuếch tán rời rạc đã chưng cất vượt 1000 ở một bước.

1. FMLM: Lỗi phân rã nhân tử của khuếch tán rời rạc

Nút thắt của mô hình tự hồi quy: Sinh tuần tự từng token, cần L lần gọi mạng cho chuỗi dài L.

Khuếch tán rời rạc buộc phải xấp xỉ:

$$\tilde{p}_{t|s}(\mathbf{y}_t \mid \mathbf{y}_s) := \prod_{l=1}^{L} p^l_{t|s}(y^l_t \mid \mathbf{y}_s)$$

- Giả định các token độc lập có điều kiện, chỉ đúng khi bước nhảy $t \to s$ rất nhỏ.
- Ví dụ đồ chơi với hai mode “new-york” và “san-diego”: ít bước sẽ sinh ra cả “new-diego” và “san-york”.
- Hậu quả ở 1 đến 4 bước: văn bản vô nghĩa với Gen. PPL trên 1000, hoặc lặp token với entropy dưới 4.

Mệnh đề 3.5: Trên tập hữu hạn, tồn tại phân phối đích không thể thu được từ phân phối nguồn bằng một ánh xạ xác định ở mức mẫu. Vì vậy khuếch tán rời rạc không có ánh xạ dòng ở mức mẫu.

2. FMLM: Mô hình dòng FLM trên biểu diễn one-hot

- **Biểu diễn:** $f(\mathbf{y}) \in \mathbb{R}^{L\times|\mathcal{V}|}$ là one-hot từng token, giải mã bằng argmax. Không cần embedding học.
- **Nội suy tuyến tính** giữa nhiễu Gaussian $\mathbf{x}_0$ và dữ liệu one-hot $\mathbf{x}_1$:

$$I_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1, \qquad \mathbf{b}_t(\mathbf{x}) = \frac{D_t(\mathbf{x}) - \mathbf{x}}{1-t}$$

- **Học vận tốc bằng sai số bình phương thất bại:** đích $\mathbf{x}_1 - \mathbf{x}_0$ có hạng đầy đủ, mạng bị underfit khi $|\mathcal{V}| \gg d$.
- **Học bộ khử nhiễu thay thế:** $D_t(\mathbf{x}) = \mathbb{E}[\mathbf{x}_1 \mid I_t = \mathbf{x}]$ chính là phân phối hậu nghiệm của từng token, nằm trên đơn hình xác suất (Bổ đề 3.1).
- **Huấn luyện bằng cross-entropy** với đầu ra softmax theo token. Mệnh đề 3.2: nghiệm tối ưu duy nhất là D_t, và sai số nhỏ kéo theo khoảng cách Wasserstein W_2 nhỏ.

3. FMLM: Tái tham số hóa thời gian theo tỉ lệ lỗi giải mã

- **Vấn đề:** Tỉ lệ lỗi giải mã $P_e(t)$ giảm rất gấp gần $t = 1$ khi $|\mathcal{V}|$ lớn. Lấy t đều làm lãng phí tín hiệu huấn luyện và lãng phí bước lấy mẫu.

$$P_e(t) = \frac{1}{L} \sum_{l=1}^{L} \mathbb{P}\big(g^l(\mathbf{x}_t) \neq g^l(\mathbf{x}_1)\big)$$

- **Đề xuất:** Huấn luyện và lấy mẫu đều theo $\tau(t)$, sao cho mỗi bước giảm cùng một lượng lỗi giải mã:

$$\tau(t) = 1 - \frac{|\mathcal{V}|}{|\mathcal{V}| - 1} P_e(t)$$

- **Cài đặt:** Bảng tra 1000 điểm tính bằng cầu phương Gauss–Hermite, nội suy spline bậc ba. Chi phí gần như bằng không.
- **Hiệu quả:** Cho phép mở rộng tới $|\mathcal{V}| \approx 50\,000$. Trên LM1B, Gen. PPL của FLM: không tái tham số hóa 149,18; thời gian entropy học được 130,42; theo tỉ lệ lỗi giải mã **106,98**.

4. FMLM: Bộ khử nhiễu hai thời điểm trên đơn hình xác suất

Ánh xạ dòng: $X_{s,t}(\mathbf{x}) = \mathbf{x} + (t-s)\,\mathbf{v}_{s,t}(\mathbf{x})$, nhảy thẳng giữa hai thời điểm bất kỳ. Sinh một bước: $\hat{\mathbf{x}}_1 = X_{0,1}(\mathbf{x}_0)$.

- *Khó khăn:* $X_{s,t}$ rời khỏi đơn hình do nhiễu Gaussian, nên khó huấn luyện bằng cross-entropy.

Định nghĩa: $\delta_{s,t}(\mathbf{x}) := \mathbf{x} + (1-s)\,\mathbf{v}_{s,t}(\mathbf{x})$. Mệnh đề 3.3:

1. **Khôi phục ánh xạ dòng:** $X_{s,t}(\mathbf{x}) = \frac{1-t}{1-s}\mathbf{x} + \frac{t-s}{1-s}\,\delta_{s,t}(\mathbf{x})$.
2. **Nằm trên đơn hình:** $\delta_{s,t}(\mathbf{x})^l \in \Delta^{|\mathcal{V}|-1}$, nên dùng được softmax.
3. **Trùng bộ khử nhiễu trên đường chéo:** $\delta_{s,s} = D_s$.
4. **Điều kiện nửa nhóm dạng tổ hợp lồi:** $\delta_{s,t} = \gamma\,\delta_{s,u} + (1-\gamma)\,\delta_{u,t}(X_{s,u})$, với $\gamma = \frac{(1-t)(u-s)}{(1-u)(t-s)} \in [0,1]$.

5. FMLM: Chưng cất nửa nhóm và sinh một bước

Hàm mục tiêu KL nửa nhóm với giáo viên FLM đóng băng $\hat{D}$ (Mệnh đề 3.4):

$$\mathcal{L}_{\mathrm{KL}} = \mathbb{E}\left[\sum_{l} \mathrm{KL}\big(\bar{\delta}^{l}_{s,t} \,\|\, \hat{\delta}^{l}_{s,t}(l_s)\big)\right] + \mathbb{E}\left[\sum_{l} \mathrm{KL}\big(\hat{D}^{l}_{t}(l_t) \,\|\, \hat{\delta}^{l}_{t,t}(l_t)\big)\right]$$

với mục tiêu giáo viên $\bar{\delta}_{s,t} = \mathrm{sg}\big(\gamma\,\hat{\delta}_{s,u}(l_s) + (1-\gamma)\,\hat{\delta}_{u,t}(\hat{x}_{s,u})\big)$.

- **Lấy mẫu bộ ba** (s,u,t)**:** chọn độ dài bước h, điểm đầu $\tau(s)$, điểm cuối $\tau(t) = \tau(s) + h$, điểm giữa u là trung điểm. Cách này tốt nhất trong các cách thử.
- **Lấy mẫu biên:** cặp $(s,t) = (0,1)$ với xác suất $1/32$, vì τ phẳng gần $t = 0$. Bỏ kỹ thuật này, Gen. PPL một bước tăng từ 119,34 lên 142,61.
- **Cấu hình:** chưng cất 100 nghìn bước, chia đôi batch cho đường chéo và ngoài đường chéo. Lấy mẫu dùng thuật toán γ của Kim et al.

6. FMLM: Kết quả của FLM ở 1024 bước

Gen. PPL theo GPT-2 Large, 1024 bước. Entropy của dữ liệu: LM1B 4,31; OWT 5,44.

Mô hình	LM1B PPL	LM1B Ent	OWT PPL	OWT Ent
RDLM	268,21	4,33	–	–
CANDI	120,99	4,35	143,13	5,71
MDLM	109,21	4,32	105,15	5,63
Duo	98,14	4,31	77,69	5,55
FLM	**96,91**	4,29	**62,23**	5,33

- Trên LM1B, FLM chỉ hơn Duo khoảng 1,3%. Trên OWT, FLM hơn rõ nhưng entropy thấp hơn dữ liệu, tác giả tự thừa nhận có đánh đổi nhỏ.
- Trên OWT, các đối chứng dùng checkpoint công bố chính thức, không huấn luyện lại cùng cấu hình.
- Mở rộng cỡ mô hình trên OWT, 150 nghìn bước: 179M, 424M, 870M cho Gen. PPL 75,57, 65,94, 61,59.

7. FMLM: Kết quả sinh một đến bốn bước

Gen. PPL, thấp hơn là tốt hơn. Dấu sao đỏ: entropy dưới 4,0, tức lặp token.

Tập, số bước	MDLM+SDTT	MDLM+Di4C	Duo+DCD	Duo+Di4C	FMLM
LM1B, 1 bước	1429,48	1217,10	1224,52	292,94*	**119,34**
LM1B, 2 bước	602,14	621,59	520,08	247,69*	**110,19**
LM1B, 4 bước	241,01	247,32	210,88	150,67	**98,76**
OWT, 1 bước	1260,86	1298,80	5743,29	370,51*	**168,30**
OWT, 2 bước	877,22	758,23	891,16	210,22	**133,29**
OWT, 4 bước	339,73	239,27	250,86	154,67	**111,31**

- Entropy của FMLM một bước: LM1B 4,16 và OWT 5,17, thấp hơn dữ liệu thật (4,31 và 5,44).
- Một bước của FMLM tương đương các mô hình đối chứng ở 8 đến 16 bước trên LM1B và 4 đến 8 bước trên OWT. Hình 1 báo tăng tốc 8,3 lần.

8. FMLM: Dẫn hướng lúc suy luận

Tự dẫn hướng ngoại suy vận tốc ra xa mô hình yếu, mô hình yếu là bản có dropout 0,1:

$$\hat{\mathbf{b}}_t^{\text{guided}} = \hat{\mathbf{b}}_t^{\text{weak}} + \eta\big(\hat{\mathbf{b}}_t - \hat{\mathbf{b}}_t^{\text{weak}}\big)$$

- FLM ổn định đến $\eta = 100$. Tại $\eta = 50$, Gen. PPL giảm từ 96,91 xuống **51,62**, nhưng entropy giảm còn 4,00.
- Duo và MDLM sụp đổ từ $\eta \geq 10$.

Dẫn hướng theo phần thưởng dựa trên nhìn trước điểm cuối của ánh xạ dòng:

$$\mathbf{x}_{t_{n+1}} = X_{t_n,t_{n+1}}(\mathbf{x}_{t_n}) + \lambda\, \nabla_{\mathbf{x}_{t_n}} r\big(X_{t_n,1}(\mathbf{x}_{t_n})\big)$$

- Bộ phân loại phần thưởng chỉ cần huấn luyện trên văn bản sạch. Khuếch tán rời rạc phải huấn luyện trên dữ liệu bị nhiễu ở mọi mức.
- Ở 2 bước, chủ đề: FMLM đạt PPL 131,8 và phần thưởng 0,670; MDLM+SDTT đạt 888,8 và 0,274. Tiêu chí ngữ pháp: phần thưởng của mọi phương pháp đều thấp.

9. FMLM: Ràng buộc logic trên Sudoku và độ đa dạng

Tỉ lệ lời giải hợp lệ, phần trăm, ở 1, 2, 4 và 1024 bước:

	Sinh không điều kiện	Giải puzzle, tập kiểm tra
MDLM+SDTT	0 / 0 / 0,02 / 92,19	0 / 2,93 / 8,40 / 98,63
Duo+DCD	0 / 0,39 / 17,19 / 91,41	0 / 30,85 / 73,82 / 96,88
FMLM	**9,38 / 57,03 / 79,69 / 94,92**	**39,84 / 85,15 / 92,19 / 98,83**

- Mọi lưới hợp lệ đều duy nhất và không trùng tập huấn luyện. Ở 1024 bước, các đối chứng ngang FMLM, nên lợi thế nằm ở vùng ít bước.
- **Độ đa dạng một bước:** Self-BLEU của FMLM là 0,073 trên LM1B và 0,121 trên OWT, dữ liệu thật là 0,047 và 0,046. Trọng tài GPT-4.1 cho FMLM thắng 39 đến 42% về đa dạng. Kết luận: không sụp đổ mode, nhưng kém đa dạng hơn dữ liệu thật, rõ nhất trên OWT.

10. FMLM: Nghiên cứu loại bỏ thành phần

Mô hình dòng FLM, Gen. PPL trên LM1B ở 1024 bước:

- **Hàm mục tiêu:** vận tốc với sai số bình phương 3801,36; bộ khử nhiễu với sai số bình phương 129,04; thêm softmax 120,16; thêm cross-entropy **96,91**.
- **Biểu diễn:** one-hot 130,42, tốt hơn embedding học được (324,66), BERT-large đóng băng (262,92), embedding ngẫu nhiên (400,17).
- **Khung khuếch tán:** Euclid 96,91. Đơn hình cho PPL 85,07 nhưng entropy sụp còn 3,76. Riemann cho 268,21.

Ánh xạ dòng FMLM, Gen. PPL một bước:

- **Tham số hóa:** vận tốc trung bình với sai số bình phương 199,01; bộ khử nhiễu hai thời điểm với softmax và cross-entropy **119,34**.
- **Mục tiêu chưng cất:** nửa nhóm 119,34; Eulerian 149,13; Lagrangian 193,08. Chưng cất tốt hơn tự chưng cất (159,53).
- **Nhiễu đầu vào:** Gaussian 105,48 so với đều trên đơn hình 660,33.

11. FMLM: Hạn chế, phản biện và kết luận

Điểm cần thận trọng khi đọc kết quả:

- Chỉ số chính là Gen. PPL theo GPT-2 Large cộng entropy, không có đánh giá của người.
- Entropy của FMLM luôn thấp hơn dữ liệu thật: một phần lợi thế PPL có thể đến từ việc dồn mẫu về mode phổ biến.
- Quy mô nhỏ: 179M tham số. Chi phí huấn luyện hai giai đoạn không được tính vào so sánh. One-hot tốn thêm khoảng 30% thời gian và bộ nhớ.

Kết luận:

1. Dòng liên tục trên one-hot cạnh tranh được với khuếch tán rời rạc ở nhiều bước và vượt rõ ở ít bước.
2. Bộ khử nhiễu hai thời điểm đưa ánh xạ dòng lên đơn hình, nên chưng cất bằng cross-entropy và KL ổn định.
3. Mở đường cho dẫn hướng và học tăng cường. Chưa có bằng chứng ở quy mô LLM.

Cảm ơn bạn đã theo dõi!

Q&A