Flow Map Language Models (FMLM)

Mô hình hóa Ngôn ngữ Đơn bước qua Khử nhiễu Liên tục

Hung Manh

October 21, 2026

Nội dung trình bày

FMLM: Tổng quan bài báo

- **Tên bài báo:** *Flow Map Language Models: One-step Language Modeling via Continuous Denoising*
- **Tác giả & Tổ chức:** Chanhyuk Lee, Nicholas M. Boffi, Jinwoo Kim et al. (KAIST & CMU, arXiv:2602.16813)
- **Ý tưởng cốt lõi:** Mô hình hóa ngôn ngữ bằng continuous flows trên biểu diễn one-hot unconstrained, chưng cất thành công mô hình sinh ngôn ngữ **1 bước (one-step)** thông qua toán tử **Two-time Denoiser** trên simplex.
- **Đóng góp nổi bật:**
  - **Phá vỡ định kiến:** Bác bỏ giả thuyết dữ liệu rời rạc bắt buộc phải dùng discrete noising; continuous flow vượt trội cả về chất lượng lẫn tốc độ.
  - **Đột phá sinh 1 bước:** FMLM sinh 1 bước đạt chất lượng vượt qua discrete diffusion 8 bước, tăng tốc **8.3**$\times$.
  - **Two-time Denoiser ($\delta_{s,t}$):** Đưa flow map về nằm trọn trên simplex xác suất, mở đường cho chưng cất bằng semigroup condition và cross-entropy.

1. FMLM: Tử huyệt Factorization Error của Discrete Diffusion

Nút thắt của Autoregressive LLMs:

- Sinh tuần tự từng token một ($O(L)$ bước), tạo ra điểm nghẽn độ trễ khi sinh chuỗi dài.

Tử huyệt Factorization Error của Discrete Diffusion:

- Không gian trạng thái $\mathcal{V}^L$ quá lớn $\rightarrow$ buộc phải dùng xấp xỉ phân rã tích:

$$\tilde{p}_{t|s}(\mathbf{y}_t|\mathbf{y}_s) := \prod_{l=1}^{L} p^l_{t|s}(y^l_t|\mathbf{y}_s)$$

- Giả định các token độc lập có điều kiện chỉ đúng trong giới hạn vô cùng bé ($t \rightarrow s$).
- *Hậu quả ở ít bước ($1 \sim 4$ bước):* Bước nhảy lớn làm mất liên kết ngữ nghĩa giữa các token $\rightarrow$ văn bản vô nghĩa (PPL > 1000) hoặc lặp từ liên tục (entropy sụp đổ < 4.0).

Mệnh đề 3.5 (Giới hạn toán học căn bản):

- Trong không gian rời rạc hữu hạn, **không thể tồn tại sample level**

2. FMLM: Mô hình cơ sở Flow LM (FLM)

- **Biểu diễn One-hot Unconstrained:** $f(\mathbf{y}) \in \mathbb{R}^{L \times |\mathcal{V}|}$, giải mã bằng $g(\mathbf{x}) = \text{argmax}(\mathbf{x})$.
- **Stochastic Interpolant:** Nội suy đường đi giữa Gaussian noise $\mathbf{x}_0 \sim \mathcal{N}(0, \mathbf{I})$ và one-hot data $\mathbf{x}_1$:

$$I_t := (1-t)\mathbf{x}_0 + t\mathbf{x}_1, \quad t \in [0,1]$$

- **Tránh nút thắt rank bottleneck:** Học vận tốc $\mathbf{b}_t = \mathbb{E}[\mathbf{x}_1 - \mathbf{x}_0 | I_t]$ bằng MSE bị underfitting nghiêm trọng do $\mathbf{x}_0$ full-rank.
- **Chuyển sang Denoiser trên Simplex (Bổ đề 3.1 & Mệnh đề 3.2):**

$$D_t(\mathbf{x}) := \mathbb{E}[\mathbf{x}_1 | I_t = \mathbf{x}] \in \Delta^{|\mathcal{V}|-1}, \quad \mathbf{b}_t(\mathbf{x}) = \frac{D_t(\mathbf{x}) - \mathbf{x}}{1-t}$$

  - D_t là phân phối hậu nghiệm của token, luôn nằm trên đơn hình xác suất simplex.
  - Huấn luyện bằng **Cross-Entropy loss**, chặn chặt khoảng cách Wasserstein $W_2^2 \leq C\epsilon$.

3. FMLM: Tái tham số hóa thời gian theo Decoding Error ($\tau(t)$)

- **Vấn đề:** Tỷ lệ lỗi giải mã $P_e(t) := \frac{1}{L}\sum_l \mathbb{P}(g^l(\mathbf{x}_t) \neq g^l(\mathbf{x}_1))$ dốc đứng sát $t = 1$.
  - Lấy mẫu đều $t \sim \mathcal{U}[0,1]$ lãng phí tín hiệu ở vùng chưa quyết định token và bỏ sót vùng quyết định then chốt khi $|\mathcal{V}|$ lớn.
- **Đề xuất hàm $\tau(t)$ chuẩn hóa tiến độ giải mã:**

$$\tau(t) = 1 - \frac{|\mathcal{V}|}{|\mathcal{V}| - 1} P_e(t)$$

- **Lợi ích thực tế:**
  - Huấn luyện và lấy mẫu đều trong miền $\tau(t) \sim \mathcal{U}[0,1]$.
  - Mỗi bước tính toán đóng góp đồng đều vào việc giảm decoding error.
  - Cài đặt $O(1)$ qua bảng tra cứu trước (LUT) kết hợp nội suy cubic spline, mở rộng thành công lên từ vựng $|\mathcal{V}| \approx 50.000$.

4. FMLM: Two-time Denoiser trên Simplex

Mục tiêu Flow Map:

- Ánh xạ trực tiếp giữa hai thời điểm bất kỳ: $X_{s,t}(\mathbf{x}) = \mathbf{x} + (t-s)\mathbf{v}_{s,t}(\mathbf{x})$.
- Cho phép sinh 1 bước qua $\hat{\mathbf{x}}_1 = X_{0,1}(\mathbf{x}_0)$.
- *Thách thức:* $X_{s,t}$ văng ra khỏi simplex do nhiễu Gaussian $\rightarrow$ dùng MSE cho chất lượng kém.

Định nghĩa Two-time Denoiser ($\delta_{s,t}$):

$$\delta_{s,t}(\mathbf{x}) := \mathbf{x} + (1-s)\mathbf{v}_{s,t}(\mathbf{x})$$

4 Tính chất cốt lõi (Mệnh đề 3.3):

1. **Phục hồi Flow Map:** $X_{s,t}(\mathbf{x}) = \frac{1-t}{1-s}\mathbf{x} + \frac{t-s}{1-s}\delta_{s,t}(\mathbf{x})$.
2. **Bảo toàn trên simplex:** $\delta_{s,t}(\mathbf{x})^l \in \Delta^{|\mathcal{V}|-1} \rightarrow$ dùng được tầng softmax.
3. **Khớp với Denoiser ở đường chéo:** $\delta_{s,s}(\mathbf{x}) = D_s(\mathbf{x})$.
4. **Thỏa mãn tính chất nửa nhóm dạng tổ hợp lồi:**

$$\delta_{s,t} = \gamma\delta_{s,u} + (1-\gamma)\delta_{u,t}(X_{s,u}), \quad \gamma = \frac{(1-t)(u-s)}{(1-u)(t-s)} \in [0,1]$$

5. FMLM: Chưng cất Semigroup & Suy luận 1 bước

Hàm mất mát Semigroup Distillation (Mệnh đề 3.4):

- Tận dụng tính chất tổ hợp lồi trên simplex, tối ưu qua KL divergence với giáo viên FLM $\hat{D}_t$ đóng băng:

$$\mathcal{L}_{\mathrm{KL}}(\hat{\delta}) = \mathbb{E}_{s,u,t}\left[\sum_{l=1}^{L} \mathrm{KL}(\bar{\delta}^{l}_{s,t} \parallel \hat{\delta}^{l}_{s,t}(I_s))\right] + \mathbb{E}_{t}\left[\sum_{l=1}^{L} \mathrm{KL}(\hat{D}_t(I_t)^{l} \parallel \hat{\delta}^{l}_{t,t}(I_t))\right]$$

với mục tiêu giáo viên nửa nhóm: $\bar{\delta}_{s,t} := sg\left(\gamma\hat{\delta}_{s,u}(I_s) + (1-\gamma)\hat{\delta}_{u,t}(\hat{X}_{s,u})\right)$.

Kỹ thuật lấy mẫu biên (Boundary Sampling):

- Do $\tau(t)$ phẳng gần $t = 0$, cố định xác suất $p = 1/32$ lấy mẫu cặp $(s,t) = (0,1)$ để bơm gradient mạnh cho bước nhảy 1-step.
- **One-step inference:** $\hat{\mathbf{x}}_1 = \hat{\delta}_{0,1}(\mathbf{x}_0)$ sau đó decode qua argmax.

6. FMLM: Kết quả thực nghiệm sinh 1 bước

Hiệu năng ở chế độ ít bước ($N = 1, 2, 4$ steps):

Bộ dữ liệu / Bước	MDLM+SDTT	MDLM+Di4C	Duo+DCD	Duo+Di4C	FMLM (Our
LM1B - 1 bước	1429.48	1217.10	1224.52	292.94*	**119.34** (Ent: 4
LM1B - 2 bước	602.14	621.59	520.08	247.69*	**110.19** (Ent: 4
LM1B - 4 bước	241.01	247.32	210.88	150.67	**98.76** (Ent: 4
OWT - 1 bước	1260.86	1298.80	5743.29	370.51*	**168.30** (Ent: 5
OWT - 4 bước	339.73	239.27	250.86	154.67	**111.31** (Ent: 5

* Mô hình bị sụp đổ Entropy (< 4.0) do lặp từ vô nghĩa liên tục.

- **Tốc độ & Chất lượng:** FMLM 1 bước đạt chất lượng tương đương mô hình rời rạc chưng cất $8 \sim 16$ bước, tăng tốc **8.3**$\times$.
- **Kiểm chứng Mode Collapse:** Self-BLEU (0.073) sát với Real data (0.047); GPT-4.1 Judge xác nhận độ đa dạng cao (39–42%), không bị lặp mẫu.

7. FMLM: Dẫn hướng trong suy luận (Guidance)

Autoguidance (Nâng cao chất lượng sinh không điều kiện):

- $\hat{\mathbf{b}}_t^{(\text{guided})} = \hat{\mathbf{b}}_t^{(\text{weak})} + \eta(\hat{\mathbf{b}}_t - \hat{\mathbf{b}}_t^{(\text{weak})})$.
- Hoạt động trong không gian Euclid: FLM ổn định với scale η lên đến **100**.
- Tại $\eta = 50$, PPL giảm mạnh từ 96.91 xuống **51.62**.
- Mô hình rời rạc sụp đổ hoàn toàn tại $\eta \geq 10$ do ngoại suy logit nhân bản lỗi phân rã nhân tử.

Reward Guidance (FMRG - Điều hướng theo thuộc tính):

- Nhờ Flow Map $X_{t_n,1}$, mô hình có khả năng **nhìn trước điểm kết thúc (look-ahead) vi phân được**:

$$\mathbf{x}_{t_{n+1}} = X_{t_n,t_{n+1}}(\mathbf{x}_{t_n}) + \lambda \nabla_{\mathbf{x}_{t_n}} r\left(X_{t_n,1}(\mathbf{x}_{t_n})\right)$$

- Reward model r (an toàn, cảm xúc, chủ đề) **chỉ cần huấn luyện trên văn bản sạch**.

8. FMLM: Cấu trúc logic (Sudoku) & Kết luận

Mô hình hóa ràng buộc logic toàn cục (Sudoku 9×9):

- *Unconditional 1-step:* FMLM đạt **9.38%** lời giải hợp lệ (tất cả các baseline rời rạc đều $= 0.00\%$).
- *Conditional 1-step (20 ô gợi ý):* FMLM giải đúng **39.84%** chỉ trong 1 forward pass.

Tổng kết 3 bài học cốt lõi:

1. **Phá vỡ định kiến:** Continuous Flow trên biểu diễn One-hot unconstrained vượt trội hơn hẳn Discrete Diffusion trên dữ liệu rời rạc.
2. **Two-time Denoiser ($\delta_{s,t}$):** Đưa Flow Map về nằm trên đơn hình xác suất, biến bài toán chưng cất thành hàm mất mát Cross-Entropy / Semigroup đơn giản và tối ưu.
3. **One-step Generation:** FMLM là mô hình đầu tiên sinh ngôn ngữ 1 bước thành công, mở ra hướng tăng tốc vượt bậc cho mô hình ngôn ngữ và RL finetuning.

Cảm ơn bạn đã theo dõi!

Q&A