Looped Flows: Recurrent Reasoning with Flow Matching

Huấn luyện Mô hình Tuần hoàn qua Mục tiêu Khử nhiễu Cục bộ

Hung Manh

October 21, 2026

Nội dung trình bày

Tóm tắt

- **Vấn đề:** Giải bài toán khó cần nhiều compute time. Các looped models thực hiện điều này qua việc cập nhật tuần hoàn hidden state. Tuy nhiên, huấn luyện gradient ngắn hạn khiến việc học các early updates gặp khó khăn.
- **Đề xuất: Looped flows** - huấn luyện recurrency với các mục tiêu khử nhiễu cục bộ.
- **Cơ chế:**
  - *Temporal alignment*: Giảm dần mức độ nhiễu và sử dụng shared noise.
  - *Inference*: Tích phân vận tốc của probability flow kết hợp với các looped states.
- **Kết quả:** Vượt qua các SOTA looped models, đạt **58.8%** trên ARC-AGI-1 và **12.2%** trên ARC-AGI-2; cho phép scale tính toán và tạo multiple valid predictions.

1. Giới thiệu: Bối cảnh & Thách thức

Bối cảnh & Động lực:

- Giải bài toán khó đòi hỏi gia tăng tính toán lúc inference.
- Khác với Autoregressive LLMs, các looped models sử dụng distributed state và cập nhật tuần hoàn để tích lũy computation.

Thách thức của Looped Models:

- Huấn luyện bằng full BPTT tốn kém bộ nhớ và dễ gặp hiện tượng vanishing/exploding gradients.
- Thực tế chỉ backprop qua vài bước $\rightarrow$ early updates không nhận được tín hiệu để hỗ trợ future computation.
- Hậu quả: Chuỗi lặp không ổn định, sinh ra các failure modes ở cả bài toán đơn giản.

1. Giới thiệu: Giải pháp Looped Flows

Đóng góp chính của Looped Flows:

- Học một chuỗi mục tiêu khử nhiễu cục bộ theo thời gian ở nhiều mức nhiễu khác nhau.
- **Temporal alignment:** Phân bổ huấn luyện theo thời gian, giảm dần mức nhiễu, sử dụng shared noise $\rightarrow$ hidden states duy trì tính hữu ích xuyên suốt.
- **Cơ chế Inference:** Giải bài toán bằng cách tích phân trường vận tốc của probability flow kết hợp với recurrent states.
- **Lợi ích:**
  - Scale compute qua một finer time grid.
  - Đưa ra nhiều dự đoán hợp lệ bằng stochastic/Euler integration.
  - Học được stable recurrency, khắc phục điểm yếu của looped models cũ.

2. Kiến thức nền: Looped Models

- **Định nghĩa:** Cập nhật hidden state $z \in \mathbb{R}^{d_z}$ qua hàm f:

$$z_i = f(z_{i-1}; c)$$

- Đưa ra dự đoán qua đầu đọc g: $\hat{x}_i = g(z_i)$.
- **Hàm loss thực tế:** Để tránh full BPTT, mô hình dùng toán tử dừng gradient $sg(\cdot)$:

$$L_{loop}(f, g) := \mathbb{E}_{c,x}\left[\sum_i CE(\hat{x}_i, x)\right] \quad \text{với } z_i = f(sg(z_{i-1}); c)$$

- *Điểm yếu:* Tổn thất tại bước $\geq i$ không truyền tín hiệu về quá khứ $z_{<i}$. Quá trình lặp deterministic chỉ cho phép 1 lời giải duy nhất.

2. Kiến thức nền: Flow and Diffusion Models

- **Continuous flow matching:** Đi từ nhiễu $x_0 \sim \mathcal{N}(0, \sigma^2 I)$ đến dữ liệu thật $x_1 \sim p_{data}$.
- **Probability path:** Nội suy $I_t := (1-t)x_0 + tx_1$.
- **Velocity field:** $\dot{x}_t = b_t(x_t; c)$.
- Tích phân số (VD: Euler tiến) để xấp xỉ lời giải:

$$x_{t_{i+1}} = x_{t_i} + (t_{i+1} - t_i)\hat{b}_{t_i}(x_{t_i}; c)$$

- **Denoising function (D_t):** Thay vì dự đoán trực tiếp vận tốc, học hàm khử nhiễu độc lập tại mỗi t:

$$L_{flow}(\hat{D}) := \mathbb{E}[CE(\hat{x}_t, x_1)]$$

- *Nhược điểm:* Khó học các tính toán tuần tự do phụ thuộc hoàn toàn vào flow.

3. Looped Flows: Cơ chế Huấn luyện

Stateful Denoiser:

- Khử nhiễu x_{t_i} đồng thời cập nhật looped state z_{t_i}:

$$(\hat{x}_{t_i}, z_{t_{i+1}}) = \hat{D}_{t_i}(I_{t_i}, sg(z_{t_i}); c)$$

Temporal Alignment:

- Sắp xếp lưới thời gian $t_0 < t_1 < \cdots < t_k$ để mức nhiễu giảm dần.
- **Shared noise:** Mẫu x_0 dùng chung cho toàn bộ quỹ đạo $\rightarrow$ ép mô hình liên kết các thời điểm, giúp z_{t_i} mang thông tin hữu ích cho tương lai.

Adaptive Computation Time (ACT):

- Dùng đầu đọc phân loại nhị phân $q(z_{t_{i+1}})$ để quyết định dừng suy luận sớm khi độ chính xác đã bão hòa.

3. Looped Flows: Cơ chế Suy luận

- **Stochastic Integration:**
  - Thêm hệ số ngẫu nhiên $\gamma \geq 0$.
  - Lùi nhẹ x_{t_i} về thời điểm $s < t_i$ (tiêm nhiễu mới) trước khi thực hiện bước Euler tiến.
  - Khi $\gamma = 0$, mô hình quay về Euler ODE truyền thống.
- **Inference-time Scaling:**
  - Giải bài toán bằng finer time grid so với lúc huấn luyện.
  - Sử dụng kỹ thuật **best-Q ensembling**: Chạy nhiều mẫu, chọn dự đoán có xác suất thành công cao nhất từ đầu đọc ACT q.

4. Nghiên cứu liên quan

- **Looped models (TRM, FPRM):** Thiếu giám sát toàn cục do cắt gradient, dễ rơi vào spurious attractors. *Looped flows giải quyết bằng cách khởi tạo lặp từ local denoising.*
- **Stochastic looped models:** Tận dụng nhiễu nhưng vẫn phụ thuộc gradient cục bộ. *Looped flows kết hợp lợi ích ngẫu nhiên và giải quyết triệt để học cục bộ.*
- **Flow & Diffusion Models:** Học khử nhiễu độc lập. *Looped flows dùng local objectives tạo lộ trình học mượt mà cho hidden state.*
- **Energy models:** *Looped flows tương đương việc học chuỗi năng lượng làm mịn giảm dần*, giúp quá trình tối ưu dễ dàng hơn.

5. Thử nghiệm: Chính xác & Khả năng mở rộng

So sánh đơn quỹ đạo (Single-trajectory):

- Looped flows áp đảo TRM, FPRM, GRAM trên:
  - Sudoku-Extreme (**97.9%**)
  - Maze-Hard (**86.7%**)
  - ARC-AGI-1 (**58.8%** - tăng từ 44.6% của TRM)
  - ARC-AGI-2 (**12.2%** - tăng từ 7.8% của TRM)

Inference-time scaling:

- Ensembling cải thiện thêm hiệu năng (Sudoku 99.3%, ARC 59.5%).
- Finer time grid tăng accuracy mạnh: Sudoku từ 74.5% (8 steps) $\rightarrow$ 97.9% (128 steps).

Độ ổn định:

- Giải quyết 90.9% các trường hợp thất bại của TRM (bao gồm non-convergence và spurious attractors).

5. Thử nghiệm: Đa dạng Lời giải & Ablation Study

Đa dạng lời giải (Diversity): Đánh giá trên bài toán đa nghiệm.

- N-Queens (8x8): **99.9%** ACC / **91.4%** Coverage.
- Graph Coloring (8 đỉnh): **0.7** conflicts / **89.4%** Coverage.
- Vượt trội hoàn toàn về khả năng tìm ra tập lời giải đa dạng nhờ probability transport.

Ablation Study:

- **Flow:** Bỏ time conditioning, bỏ interpolant, không giảm nhiễu, hay không chia sẻ nhiễu đều làm giảm mạnh hiệu năng.
- **Recurrence:** So với mô hình không lặp (FLM) hoặc self-conditioning, Looped flows đạt khả năng tổng quát hóa tốt nhất trên test set.
- Tích phân SDE ($\gamma = 5$) cho kết quả tốt hơn Euler ODE ($\gamma = 0$).

6. Kết luận

- **Looped Flows** là một framework thanh lịch, giải quyết vấn đề huấn luyện của Looped Models thông qua các mục tiêu khử nhiễu cục bộ.
- **Temporal alignment** giúp trạng thái lặp xây dựng computation hữu ích trên toàn cục, khắc phục hoàn toàn điểm yếu của gradient ngắn hạn.
- Mở ra khả năng **inference-time scaling** mạnh mẽ qua lưới thời gian mịn và tích phân ngẫu nhiên.
- **Hướng tương lai:** Phát triển các thuật toán huấn luyện không cần mô phỏng (simulation-free training).

Cảm ơn bạn đã theo dõi!

Q&A